

TIRT - wyszukiwanie obiektów na filmie

1 Opis projektu

Projekt ma na celu wykrywanie obiektów na filmie. W zależności od potrzeb mogą to być różnego rodzaju obiekty. Ze względu na to, że program działa bezpośrednio na pikselach obrazu, poza mocą obliczeniową maszyny, nie ma ograniczeń co do złożoności wykrywanych obrazów.

Przyjęta metoda polega na przeszukaniu każdej klatki filmu pod kątem wykrycia danego obrazu poprzez okno przesuwne. Dla każdego okna wyznaczana jest klasa (w szczególności, klasyfikator może stwierdzić, że nic tam nie ma). Taka para (okno, klasa) staje się kandydatem na wykrycie obiektu. Dopiero kiedy kilka klatek filmu posiada takiego samego kandydata w bliskim położeniu, wówczas kandydat taki zostaje uznany za wykryty obiekt.

2 Opis algorytmów

2.1 Klasyfikator

Użyta w projekcie metoda klasyfikacji obrazu jest metodą hashowania opisaną w [1]. Algorytm polega na obliczeniu liniowej kombinacji składowych obrazu dla każdego bitu hashu:

$$H_i(x) = \text{sgn}(w_i \cdot x + b_i) / 2 + 0.5 \quad (1)$$

gdzie:

x jest wektorem złożonym ze składowych obrazu (subpiksele obrazu).

H_i - i -ty bit hashu.

w_i - wektor wag wyznaczane przez algorytm uczący.

b_i - przesunięcie wyznaczone przez algorytm uczący.

Tak wyznaczonych hash obrazu jest kompaktową informacją o zawartości obrazu. Aby wyznaczyć klasę obrazu, należy znaleźć najbliższy (w sensie odległości Hamminga) hash w bazie. Klasa znalezionej obrazu z bazy jest klasą testowanego obrazu. Zestaw wag w_i oraz b_i nazywamy modelem.

2.1.1 Uczenie

Najważniejszym elementem algorytmu hashowania jest uczenie, i.e. wyznaczenie w_i i b_i . Metoda opiera się na analizie głównych składowych (ang. Principal Component Analysis, PCA). Wyznaczana jest macierz kowariancji z obrazów ze zbioru uczącego. Wektory własne o największych wartościach własnych stają się wektorami wag w_i . Przy czym nie muszą to być wektory własne w sensie formalnym, e.g. nie muszą być ortogonalne. Wersja nadzorowana wykorzystuje także zmodyfikowaną macierz kowariancji, która uwzględnia wiedzę o zaklasyfikowanych przykładach ze zbioru uczącego.

2.1.2 Specyfikacja

Algorytm uczący został zaimplementowany w języku c++ w środowisku Visual Studio Express 2013 z użyciem biblioteki Eigen. Składa się z dwóch aplikacji:

- SPLH - generująca model
- MakeHash - generująca bazę hashy

Obrazy są rozmiaru 32×32 RGB, reprezentowane w postaci wektora. Kolejność wartości jest następująca: najpierw wyłącznie składowe czerwone, wiersz po wierszu, następnie składowe zielone, na koniec niebieskie:

$$x = [r_{0,0}, r_{1,0}, \dots, r_{31,0}, r_{0,1}, \dots, r_{31,31}, g_{0,0}, \dots, g_{31,31}, b_{0,0}, \dots, b_{31,31}] \quad (2)$$

gdzie $r_{x,y}$ to składowa czerwona o współrzędnych x - nr kolumny i y - nr wiersza. Wartości są z przedziału $(0, 1)$. Wagi mają w_i mają taki sam układ jak dane x .

Pliki ze zbiorami uczącymi są plikami binarnymi o następującej budowie: Ciąg par (*klasa, obraz*), przy czym klasa jest liczbą 1 bajtową (255 - oznacza brak klasy), a obraz wektorem $32 \cdot 32 \cdot 3 = 3072$ bajtów (pojedyncza składowa jest 1 bajtowa) w układzie jak w 2.

Plik z modelem (class.txt) - plik tekstowy o następującej postaci:

N K
 $b_0 \ w_0^{(1)} \ w_0^{(2)} \ \dots \ w_0^{(K)}$
 $b_1 \ w_1^{(1)} \ w_1^{(2)} \ \dots \ w_1^{(K)}$
...
 $b_N \ w_N^{(1)} \ w_N^{(2)} \ \dots \ w_N^{(K)}$
Oznaczenia b_i oraz w_i zdefiniowano powyżej.

Plik z bazą (img_base.txt) - plik tekstowy o następującej postaci:

$c_0 \ H_0(x_0) \ H_1(x_0) \ \dots \ H_N(x_0)$
 $c_1 \ H_0(x_1) \ H_1(x_1) \ \dots \ H_N(x_1)$
...

gdzie c_i jest klasą i -tego obrazu, a $H_k(x_i)$ jest k -tym bitem i -tego obrazu.

2.1.3 Użycie

Generowanie modelu (wag):

```
SPLH.exe data_batch1.bin data_batch2.bin > class.txt
```

Generowanie bazy hashy:

```
MakeHash.exe class.txt data_batch1.bin data_batch2.bin > img_base.txt
```

2.2 Fast hash search

Sprawne wyszukiwanie hashy w bazie wymaga szybszego algorytmu niż liniowe przeszukiwanie. W projekcie zastosowano algorytm zaprezentowany w [2]. Idea jest naprawdę prosta. N bitowy hash jest dzielony na K równych fragmentów o rozmiarze N/K . Jeśli chcemy wyszukiwać hashe odległe o co najwyżej D , wówczas dla każdego z K fragmentów realizowanej jest wyszukiwanie sąsiadów odległych o co najwyżej D/K . Są to kandydaci na poszukiwane hashe.

2.2.1 Implementacja

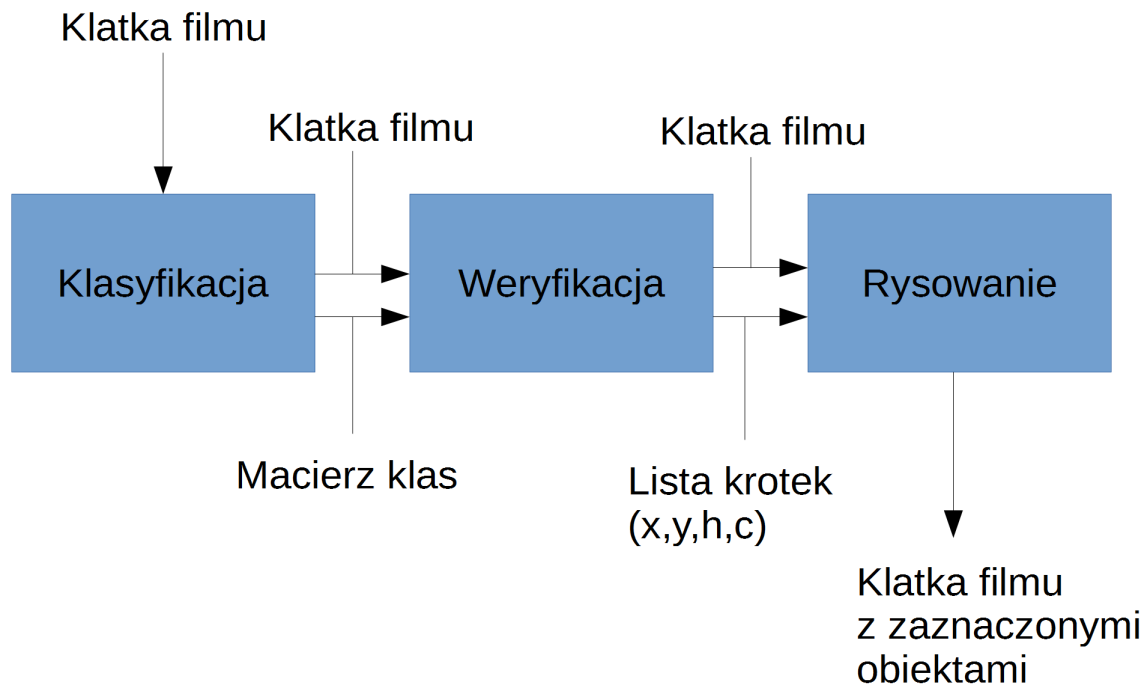
Przykładowo dla $N = 64$, $K = 4$, oraz $D = 4$, mamy fragmenty wielkości 16. Daje to 65536 możliwych fragmentów. Tak mała liczba umożliwia przygotowanie listy odpowiadających hashy dla każdego możliwego fragmentu. Wyszukanie kandydatów i -tego fragmentu sprowadza się do sprawdzenia 17 wcześniej przygotowanych list hashy.

Kiedy w bazie znajdowało się ok. 50 000 hashy, liczba przeszukiwanych hashy dla wyżej podanej konfiguracji wynosiła ok. 100.

3 Architektura aplikacji

Właściwa aplikacja wykrywająca składa się z modułów:

- Klasyfikacja
- Weryfikacja
- Rysowanie



3.1 Klasyfikacja(classifier.py)

Moduł klasyfikujący buduje macierz klas kandydatów. Wejściem są kolejne klatki filmu. Tutaj realizowane jest okno przesuwne. Zachowanie się okna definiowane jest przez konfigurację. Dla każdego położenia okna wycinany jest obraz w nim zawarty, który następnie jest skalowany do rozmiaru klasyfikatora. W tym momencie obraz jest trójwymiarową tablicą liczb z zakresu (0-255). Ze względu na problemy z odczytem takiej tablicy w module klasyfikującym należy tablicę spłaszczyć do jednego wymiaru.

Konfiguracja okna przesuwnego znajduje się w pliku (config.json). Znaczenie elementów konfiguracji:


horizontal_density - liczba położenia okna w poziomie

vertical_density - liczba położenia okna w pionie

size - wielkość okna

classifier_size - wielkość klasyfikatora

classes - tablica kolorów (w systemie BGR) przypisanych kolejnym klasom.



Przesunięcie ramki wynika z następujących wzorów:

$$\Delta x = (frame_width - size) / (horizontal_density - 1)$$

$$\Delta y = (frame_height - size) / (vertical_density - 1)$$

Wygenerowana macierz jest postaci:

$m_{i,j}$ - klasa obrazu w i -tym przesunięciu pionowym i j -tym przesunięciu poziomym. W przypadku braku klasy wartość -1 .

Moduł wysyła dalej klatkę filmu i macierz klas.

3.2 Weryfikacja(verifier.py)

Moduł weryfikujący bada kilka następujących klatek w celu potwierdzenia poprawności klasyfikacji kandydatów. Aktualna implementacja porównuje każdą klatkę z następną i poprzednią. Dla każdego elementu macierzy klas poszukiwana jest taka sama klasa w macierzy klas poprzedniej i następnej klatki w odległości (w metryce maksimum) co najwyżej 1.

Moduł generuje listę wykrytych obiektów w postaci krotki: (x, y, h, c) , gdzie:

x i y - współrzędne lewego górnego rogu kwadratu w którym znajduje się wykryty obiekt

h - wielkość kwadratu w którym został wykryty obiekt

c - klasa wykrytego obiektu

Dalej wysyłane są klatka filmu i lista obiektów.

3.3 Rysowanie (picasso.py)

Moduł rysujący rysuje kwadraty obejmujące wykryte obiekty. Otrzymuje klatkę filmu oraz listę obiektów opisaną w Weryfikacji. Dorysowuje na otrzymanej klatce obramowanie wykrytych obiektów oraz wysyła dalej zmodyfikowaną klatkę. Kolory obramowania pochodzą z konfiguracji (config.json).

4 Dalszy rozwój

4.1 Klasyfikator

Wykorzystany klasyfikator jest klasyfikatorem typu jednowarstwowa sieć neuronowa, przez co może mieć problemy z rozpoznawaniem bardziej złożonych obiektów. Dobrym pomysłem może być wykorzystanie klasyfikatora wielowarstwowego (e.g. typu autoencoder). Pomysł polega na rekurencyjnym uczeniu zaimplementowanym już algorytmem na danych przetworzonych przez poprzedni przebieg. Przedstawiają to następujące kroki:

Dane 1 - dane uczące jak obecnie

Warstwa 1 - uczenie jak obecnie

Dane 2 - dane 1 przetworzone przez warstwę 1

Warstwa 2 - uczenie jak obecnie, ale na danych 2

Dane 3 - dane 2 przetworzone przez warstwę 2

Warstwa 3 - uczenie jak obecnie, ale na danych 3

... itd. Przy czym każda kolejna warstwa powinna mieć coraz mniej elementów.

4.2 Statystyki

Ze względu na zdecydowanie zbyt małą spójność wykrytych obiektów postanowiono odłożyć moduł odpowiedzialny za generowanie statystyk na przyszłość. Kiedy osiągnięta zostanie lepsza jakość wykrycia, będzie to z pewnością przydatny moduł. Aby zrealizować ten pomysł wystarczy przesyłać listę wykrytych obiektów w module weryfikującym do nowego modułu statystyki, który zapisywałby w postaci pliku strukturalnego (e.g. xml) informacje o obiekcie (typ, położenie, wielkość).

4.3 Rozmiar okna

Ze względu na niewystarczającą wydajność projekt został uproszczony tak, aby wykorzystywana była jedna wielkość okna przesuwne. Nie jest to znaczącym ograniczeniem możliwości systemu, ponieważ można uruchomić kilka instancji systemu, każdy dla innej wielkości okna przesuwne. Daje to automatycznie większą możliwość rozproszenia oraz lepiej wykorzystuje maszyny wieloprosesorowe/wielordzeniowe.

Literatura

- [1] Jun Wang, Sanjiv Kumar, and Shih-Fu Chang, Semi-Supervised Hashing for Large Scale Search.
- [2] Mohammad Norouzi, Ali Punjani, David J. Fleet, Fast Search in Hamming Space with Multi-Index Hashing, Department of Computer Science, University of Toronto.